

Projet analyse de données

Nada Naffeti

2024-04-16

Introduction

Mon projet vise à explorer les préférences sportives en Tunisie. À travers une enquête approfondie, j'ai recueilli des données sur les choix, les habitudes et les motivations des individus en matière de pratique sportive.

Importation de la base

```
library(readr)
data <- read_csv("C:/Users/nafe/Downloads/Formulaire sans titre (réponses) - Réponses au formulaire 1

## Rows: 56 Columns: 47
## -- Column specification -----
## Delimiter: ","
## chr (28): Horodateur, Sexe, fumeur/fumeuse, Age, Catégorie socioprofessionne...
## dbl (19): Plaisir sport, Motivation sport, Environnement sport, Influence ch...
##
## i Use 'spec()' to retrieve the full column specification for this data.
## i Specify the column types or set 'show_col_types = FALSE' to quiet this message.

View(data)
```


La base de données obtenue est une base de 56 lignes et 47 colonnes.

Distribution de l'Interet sportif

```
# Distribution de l'Interet sportif

interet_sportif_table <- table(data$'Intérêt sportif')
mes_couleurs <- c("#1F77B4", "#FF7F0E", "#2CA02C", "#D62728", "#9467BD")
pie(interet_sportif_table,
    main = "Intérêt sportif",
    labels = paste(names(interet_sportif_table), " (", round(100 * interet_sportif_table / sum(interet_
    col = mes_couleurs,
    clockwise = TRUE)
```

Intérêt sportif




Interprétation : Parmi les participants, 51,8 % ont montré un intérêt pour le sport, tandis que 26,8 % se sont révélés très intéressés. Environ 10,7 % sont restés neutres, 7,1 % ont affiché un intérêt modéré, et seulement 3,6 % ont déclaré ne pas être du tout intéressés par le sport.

Répartition par genre:

```
couleurs_sexe <- c("#FF9999", "#66B2FF")
pourcentages <- round(100 * table(data$`Sexe`) / sum(table(data$`Sexe`)), 1)

pie(table(data$`Sexe`),
    col = couleurs_sexe,
    main = "Répartition par genre ",
    labels = paste(names(table(data$`Sexe`)), " (", pourcentages, "%)", sep = ""))
```

Répartition par genre



Interprétation :


D'après ce résultat, sur un échantillon de 56 personnes interrogées, 55,4 % sont des hommes tandis que 44,6 % sont des femmes. Les hommes semblent être plus enclins à pratiquer le sport que les femmes.

Répartition par professions:

```
# Distribution de la Catégorie socioprofessionnelle
colors <- c("#1F77B4", "#FF7F0E", "#2CA02C", "#D62728", "#9467BD", "#8C564B")
pourcentages <- round(100 * table(data$`Catégorie socioprofessionnelle`) / sum(table(data$`Catégorie socioprofessionnelle`)))

pie(table(data$`Catégorie socioprofessionnelle`),
     col = colors,
     main = "Répartition des catégories socioprofessionnelles",
     labels = paste(names(table(data$`Catégorie socioprofessionnelle`)), " (", pourcentages, "%)", sep = " ")
```

Répartition des catégories socioprofessionnelles



Interpretation:


La majorité des personnes interrogées étaient des étudiants, représentant environ 67,9% de l'échantillon. Ils étaient suivis par les élèves, qui constituaient environ 14,3% des répondants. Ensuite, environ 8,9% étaient des employés, tandis que 7,1% étaient des personnes en recherche d'emploi. Enfin, une minorité de 1,8% étaient des retraités.

Répartition par Age:

```
# Distribution de l'Age
age_table <- table(data$'Age')
pourcentages <- round(100 * age_table / sum(age_table), 1)
mes_couleurs <- c("#1F77B4", "#FF7F0E", "#2CA02C", "#D62728", "#9467BD", "#8C564B", "#E377C2", "#7F7F7F", "#AEC7E8", "#B22222", "#17BECF", "#A5A5A5")

pie(age_table,
    main = "Répartition par catégories d'âge",
    labels = paste(names(age_table), " (", pourcentages, "%)", sep = ""),
    col = mes_couleurs,
    init.angle = 120,
    clockwise = TRUE)
```

Répartition par catégories d'âge




Les données révèlent une nette prédominance des jeunes adultes, avec 80.4% des répondants âgés de 18 à 25 ans. Cette concentration importante de jeunes dans l'enquête indique un vif intérêt pour le sport dans cette tranche d'âge

Répartition selon la fréquence hebdomadaire

```
# Distribution de la Fréq. hebdo
freq_hebdo_table <- table(data$`Fréq. hebdo`, exclude = NULL)
categories_freq_hebdo <- c("0 fois", "1 fois", "2 fois", "3 fois", "plus de 3 fois")
freq_hebdo_selected <- freq_hebdo_table[categories_freq_hebdo]
pie(freq_hebdo_selected,
    main = "Répartition selon la fréquence hebdomadaire",
    labels = paste(names(freq_hebdo_selected), " (", round(100 * freq_hebdo_selected / sum(freq_hebdo_s
    col = rainbow(length(freq_hebdo_selected)))
```

Répartition selon la fréquence hebdomadaire



Les données révèlent que la plupart des répondants pratiquent le sport deux fois par semaine(38.9%), suivis par ceux qui le font une fois par semaine(29.6%). Cependant, un petit pourcentage ne pratique pas du tout le sport(7.4%).

Analyse en composantes principales :

1.Matrice de corrélation:


```
library(corrplot)
```

```
## corrplot 0.92 loaded
```

```
X <- as.matrix(data[, c(19:27)])  
M<- cor(X)
```

```
col <- colorRampPalette(c("#E6F0F3", "#BDD7E7", "#8CBEDB", "#539ACF", "#0D6BA4"))(100)
```

```
corrplot(M, type = "upper", order = "hclust", col = col, tl.col = "black", tl.cex = 0.7)
```



Interpretation: La matrice de corrélation indique que les variables “relâchement du stress”, “bien-être mental” et “habitudes de santé” sont fortement corrélées entre elles.

2.Choix de nombre d’axes:

```
library(FactoMineR)
library(factoextra)
```

```
## Le chargement a nécessité le package : ggplot2
```

```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```


```
res.pca=PCA(X,ncp = 3,graph= F)
head(res.pca$eig)
```

```
##      eigenvalue percentage of variance cumulative percentage of variance
## comp 1  5.0170092                55.744547                55.74455
## comp 2  0.9328180                10.364644                66.10919
## comp 3  0.9035864                10.039849                76.14904
## comp 4  0.6727815                 7.475350                83.62439
## comp 5  0.5303429                 5.892699                89.51709
## comp 6  0.3750867                 4.167629                93.68472
```

Interprétation:

Les trois premières composantes principales expliquent environ 76% de la variance totale des données, tandis que les quatre premières composantes expliquent environ 84% de la variance totale.

```
library(ggplot2)
library(factoextra)
fviz_eig(res.pca, addlabels = TRUE) +
  ggtitle("Diagramme de l'éboulis : Valeurs propres")
```



Interprétation : 1-Critère de Kaiser : On retiendrait les composantes principales dont l'eigenvalue est supérieure à 1, ce qui signifie que la première composante principale sera retenue.

2-Critère du taux d'inertie cumulée : Selon le critère du taux d'inertie cumulée, on pourrait retenir les trois premières composantes principales qui expliquent 76.14% de l'inertie totale.

3-Critère du coude : On peut voir que le coude se situe après la deuxième composante principale, ce qui indique que l'on peut se contenter de retenir les deux premières composantes principales.

=> Nous pourrions retenir les deux premières composantes principales qui expliquent environ 66.10% de l'inertie totale.

Interpretation de la carte des variables :

```
res.pca$var$coord
```


##	Dim.1	Dim.2	Dim.3
## Plaisir sport	0.6424452	-0.66931663	-0.16935688
## Motivation sport	0.8842268	-0.27365038	0.06024547
## Environnement sport	0.7649560	-0.22049739	0.35516141
## Influence choix pratique	0.5704586	0.19891012	0.68776615
## Bien-être mental	0.8036857	0.19311567	-0.31062394
## Encouragement limites	0.7443297	0.35101024	-0.07039367
## Socialisation sport	0.6782995	0.34264500	0.02279613
## Relâchement stress	0.8973811	-0.06176998	-0.05423910
## Habitudes santé	0.6682178	0.20010345	-0.40891219

```
fviz_pca_var(res.pca, shadow=TRUE)
```





Tableau des cosinus carrés des variables sur les axes de l'ACP :

```
res.pca$var$cos2
```

##	Dim.1	Dim.2	Dim.3
## Plaisir sport	0.4127359	0.44798475	0.0286817516
## Motivation sport	0.7818571	0.07488453	0.0036295172
## Environnement sport	0.5851576	0.04861910	0.1261396252
## Influence choix pratique	0.3254230	0.03956524	0.4730222731
## Bien-être mental	0.6459108	0.03729366	0.0964872319


```
## Encouragement limites 0.5540268 0.12320819 0.0049552688
## Socialisation sport 0.4600902 0.11740560 0.0005196637
## Relâchement stress 0.8052929 0.00381553 0.0029418797
## Habitudes santé 0.4465151 0.04004139 0.1672091828
```

```
fviz_pca_var(res.pca, col.var = "cos2")+
  scale_color_gradient2(low="white", mid="blue",
    high="red", midpoint = 0.6)+
  theme_minimal()
```



La carte des individus :

```
fviz_pca_ind(res.pca, geom = "text", col.ind="cos2")+
  scale_color_gradient2(low="blue", mid="white",
    high="red", midpoint=0.5)
```



Analyse en composantes multiples :

```
library(FactoMineR)
library(factoextra)
l.active<-data[,43:47]
res.mca <- MCA (l.active, graph = FALSE)
```


1.Visualisation et interpretation :

```
res.mca$eig
```


```
##      eigenvalue percentage of variance cumulative percentage of variance
## dim 1  0.2734746          27.34746          27.34746
## dim 2  0.2476248          24.76248          52.10994
## dim 3  0.1737525          17.37525          69.48519
## dim 4  0.1647011          16.47011          85.95530
## dim 5  0.1404470          14.04470         100.00000
```

```
library(ggplot2)
library(factoextra)
```

```
fviz_eig(res.mca, addlabels = TRUE) +  
  ggtitle("Diagramme de l'éboulis : Valeurs propres")
```



```
fviz_mca_var(res.mca,  
  col.var = "contrib", # Couleur en fonction de la contribution  
  gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), # Choix de couleurs  
  repel = TRUE, # Évite le chevauchement des labels  
  ggtheme = theme_minimal() # Style du graphique  
)
```




```
dimdesc(res.mca, axes=1:2, proba=0.05)$`Dim 1`
```

```
##
## Link between the variable and the categorical variable (1-way anova)
## =====
##               R2      p.value
## Comfort      0.4581453 1.021694e-08
## Technicité   0.3684103 7.077470e-07
## Esthétique   0.3006602 1.215522e-05
## Prix         0.2381300 1.361554e-04
##
## Link between variable and the categories of the categorical variables
## =====
##               Estimate      p.value
## Comfort=Comfort_non      0.9536879 1.021694e-08
## Technicité=Technicité_oui 0.3278225 7.077470e-07
## Esthétique=Esthétique_non 0.2874797 1.215522e-05
## Prix=Prix_oui            0.2946693 1.361554e-04
## Prix=Prix_non            -0.2946693 1.361554e-04
## Esthétique=Esthétique_oui -0.2874797 1.215522e-05
## Technicité=Technicité_non -0.3278225 7.077470e-07
## Comfort=Comfort_oui      -0.9536879 1.021694e-08
```

```
dimdesc(res.mca, axes=1:2, proba=0.05)$`Dim 2`
```

```
##
## Link between the variable and the categorical variable (1-way anova)
## =====
##           R2           p.value
## Marque      0.65009808 6.452265e-14
## Prix        0.36971721 6.681680e-07
## Esthétique  0.10733343 1.370845e-02
## Comfort     0.07867635 3.626778e-02
##
## Link between variable and the categories of the categorical variables
## =====
##           Estimate      p.value
## Marque=Marque_non      0.4363026 6.452265e-14
## Prix=Prix_non          0.3493826 6.681680e-07
## Esthétique=Esthétique_non 0.1634464 1.370845e-02
## Comfort=Comfort_non     0.3760671 3.626778e-02
## Comfort=Comfort_oui    -0.3760671 3.626778e-02
## Esthétique=Esthétique_oui -0.1634464 1.370845e-02
## Prix=Prix_oui          -0.3493826 6.681680e-07
## Marque=Marque_oui      -0.4363026 6.452265e-14
```


```
fviz_mca_ind (res.mca,select.ind = list(cos2 = 0.4),
  repel = TRUE,
  ggtheme = theme_minimal ())
```



Classification :

```
new<-data[19:27]
c<-dist(scale(new),method="euclidean")
h<- hclust(c, method="ward.D2")
plot(h, hang = -1, cex =0.6)
```


Cluster Dendrogram




```
library(FactoMineR)
res.HCPC<-HCPC(new, consol=TRUE, graph=F)
```

```
## Warning: Unknown or uninitialised column: 'call'.
## Unknown or uninitialised column: 'call'.
```

```
plot.HCPC(res.HCPC,choice='tree', title ='Hierarchical tree')
```



```
plot.HCPC(res.HCPC, choice = 'map', draw.tree=FALSE, title = 'Factor map')
```

```
plot.HCPC(res.HCPC,choice = '3D.map', ind.names=FALSE, centres.plot=FALSE, angles=60,title='Hierarchical tree on the factor map')
```


```
## Warning in title(main, sub, ...): "centres.plot" n'est pas un paramètre
## graphique
```

```
## Warning in title(main, sub, ...): "angles" n'est pas un paramètre graphique
```

```
## Warning in plot.xy(xy.coords(x, y), type = type, ...): "centres.plot" n'est pas
## un paramètre graphique
```

```
## Warning in plot.xy(xy.coords(x, y), type = type, ...): "angles" n'est pas un
## paramètre graphique
```

Hie rarchical tree on the factor map



```
res.HCPC$desc.var
```

```
##
## Link between the cluster variable and the quantitative variables
## =====
##
##          Eta2      P-value
## Relâchement.stress    0.7076778 7.003858e-15
## Motivation.sport      0.6128799 1.196501e-11
## Bien-être.mental      0.5824406 8.892695e-11
## Encouragement.limite  0.5742397 1.488937e-10
## Socialisation.sport   0.5016189 9.669009e-09
## Environnement.sport   0.4895521 1.822687e-08
## Habitudes.santé       0.3468489 1.252743e-05
## Influence.choix.pratique 0.2997518 7.928253e-05
## Plaisir.sport         0.2997332 7.933854e-05
##
## Description of each cluster by quantitative variables
## =====
## $'1'
##
##          v.test Mean in category Overall mean sd in category
## Habitudes.santé      -2.946496      2.333333      4.017857      1.885618
## Plaisir.sport        -3.110639      2.333333      3.982143      0.942809
## Socialisation.sport  -3.503832      1.000000      3.125000      0.000000
## Influence.choix.pratique -3.696932      1.000000      3.160714      0.000000
## Encouragement.limite -4.572655      1.000000      3.714286      0.000000
## Environnement.sport  -4.619555      1.000000      3.732143      0.000000
```

```

## Bien-être.mental      -4.943104      1.000000      4.017857      0.000000
## Relâchement.stress    -5.347882      1.000000      4.053571      0.000000
## Motivation.sport      -5.456250      1.000000      3.946429      0.000000
## Overall sd      p.value
## Habitudes.santé      1.0087310 3.213969e-03
## Plaisir.sport      0.9352439 1.866829e-03
## Socialisation.sport  1.0700884 4.586143e-04
## Influence.choix.pratique 1.0312403 2.182206e-04
## Encouragement.limite 1.0473484 4.815835e-06
## Environnement.sport  1.0435357 3.845645e-06
## Bien-être.mental      1.0772165 7.688859e-07
## Relâchement.stress    1.0074658 8.898937e-08
## Motivation.sport      0.9528087 4.862956e-08
##
## $'2'
## v.test Mean in category Overall mean sd in category
## Encouragement.limite -2.173182      3.384615      3.714286      0.6837073
## Habitudes.santé      -2.491418      3.653846      4.017857      0.7816308
## Socialisation.sport  -3.039838      2.653846      3.125000      0.6760921
## Overall sd      p.value
## Encouragement.limite  1.047348 0.029766637
## Habitudes.santé      1.008731 0.012723451
## Socialisation.sport  1.070088 0.002367053
##
## $'3'
## v.test Mean in category Overall mean sd in category
## Socialisation.sport  4.612932      3.814815      3.125000      0.8622553
## Relâchement.stress    4.354736      4.666667      4.053571      0.4714045
## Encouragement.limite  4.229579      4.333333      3.714286      0.7200823
## Bien-être.mental      3.817941      4.592593      4.017857      0.4913518
## Habitudes.santé      3.814412      4.555556      4.017857      0.6285394
## Environnement.sport  3.360650      4.222222      3.732143      0.7370277
## Plaisir.sport      3.253858      4.407407      3.982143      0.6241592
## Motivation.sport      3.183939      4.370370      3.946429      0.5543196
## Influence.choix.pratique 2.482846      3.518519      3.160714      0.7874182
## Overall sd      p.value
## Socialisation.sport  1.0700884 3.970279e-06
## Relâchement.stress    1.0074658 1.332271e-05
## Encouragement.limite  1.0473484 2.341296e-05
## Bien-être.mental      1.0772165 1.345701e-04
## Habitudes.santé      1.0087310 1.365075e-04
## Environnement.sport  1.0435357 7.775922e-04
## Plaisir.sport      0.9352439 1.138494e-03
## Motivation.sport      0.9528087 1.452855e-03
## Influence.choix.pratique 1.0312403 1.303374e-02

```

```
res.HCPC$desc.axes
```

```

##
## Link between the cluster variable and the quantitative variables
## =====
##      Eta2      P-value
## Dim.1 0.8625092 1.459672e-23
## Dim.8 0.2019278 2.535816e-03

```

```

##
## Description of each cluster by quantitative variables
## =====
## $'1'
##          v.test Mean in category Overall mean sd in category Overall sd
## Dim.1 -5.786439          -7.490356 -2.868985e-15      0.3179693  2.283995
##          p.value
## Dim.1 7.189426e-09
##
## $'2'
##          v.test Mean in category Overall mean sd in category Overall sd
## Dim.1 -2.361253          -0.7811424 -2.868985e-15      0.9212333  2.2839950
## Dim.8 -3.213556          -0.2059328  1.735777e-15      0.4169140  0.4424326
##          p.value
## Dim.1 0.018213323
## Dim.8 0.001311021
##
## $'3'
##          v.test Mean in category Overall mean sd in category Overall sd
## Dim.1 4.964253           1.584473 -2.868985e-15      0.8118714  2.2839950
## Dim.8 2.498784           0.154494  1.735777e-15      0.3868027  0.4424326
##          p.value
## Dim.1 6.896595e-07
## Dim.8 1.246204e-02

```